

Библиотека Pandas.

Pandas е библиотека в Python за работа с даннови множества (datasets). Главно използваме Pandas за анализиране, изчистване и манипулиране на данни. С Pandas можем да видим "каква история ни разказват" данните, посредством различни математически и статистически похвати.

Инсталиране и import на Pandas

Можем да инсталираме Pandas с добре-познатата вече pip команда, която пишем в терминал.

```
pip install pandas
```

За да използваме библиотеката в дадено приложение е нужен import: `import pandas as pd` Както и при NumPy отново имаме стандартен псевдоним за библиотеката.

Pandas Series

Pandas Series представя данни, които означават колона на таблица, т.е. представлява едномерен масив, съдържащ данни от някакъв тип.

Label на Pandas Series

Ако нямаме изрично посочен label за даден Pandas Series, то стойностите се индексират като масив (0, 1, 2...).

```
In [1]: import pandas as pd

my_pd_series = pd.Series([1.1, 2.2, 3.3])

print(my_pd_series)

print(f'my_pd_series[1] -> {my_pd_series[1]}')

0    1.1
1    2.2
2    3.3
dtype: float64
my_pd_series[1] -> 2.2
```

Можем да създадем и custom label. Можем да достъпваме елементите както с квадратни скоби, така и с точка

In [2]: `import pandas as pd`

```
my_pd_series = pd.Series([1.1, 2.2, 3.3], index=['a', 'b', 'c'])

print(my_pd_series)
print(my_pd_series['b'])
print(my_pd_series.c)
```

```
a    1.1
b    2.2
c    3.3
dtype: float64
2.2
3.3
```

Можем да създадем Pandas Series и от речник като ключовете станат labels.

In [3]: `import pandas as pd`

```
my_dict = {
    'meal1': 600,
    'meal2': 500,
    'meal3': 700,
    'meal4': 650
}

my_pd_series = pd.Series(my_dict)

print(my_pd_series)
print(my_pd_series.meal3)
```

```
meal1    600
meal2    500
meal3    700
meal4    650
dtype: int64
700
```

Pandas DataFrames

Pandas DataFrame представлява двумерна структура от данни, приличаща на двумерен масив или по-скоро таблица с редове и колони.

In [4]: `import pandas as pd`

```
data = {
    'food': ['apple', 'pizza', 'chicken'],
    'calories': [150, 400, 250]
}

df = pd.DataFrame(data)

print(df)
```

	food	calories
0	apple	150
1	pizza	400
2	chicken	250

Индексиране на редове/колони

In [5]: *# Индексиране на колона*

```
print(df['food\']: ')
print(df['food'])
print('-----\n')

print(df.calories)
print(df.calories)
print('-----\n')

# Индексиране на ред
print(df.loc[1])
print(df.loc[1])
```

```
df['food']:
0    apple
1    pizza
2   chicken
Name: food, dtype: object
-----
```

```
df.calories
0    150
1    400
2    250
Name: calories, dtype: int64
-----
```

```
df.loc[1]
food      pizza
calories    400
Name: 1, dtype: object
```

Индексите могат да бъдат не само естествени числа, т.е. могат да бъдат именувани.

In [6]: **import** pandas **as** pd

```
data = {
    'food': ['apple', 'pizza', 'chicken'],
    'calories': [150, 400, 250]
}

df = pd.DataFrame(data, index=['meal1', 'meal2', 'meal3'])

print(df)
print('-----\n')
print(df.loc['meal1'])
```

	food	calories
meal1	apple	150
meal2	pizza	400
meal3	chicken	250

```

food      apple
calories  150
Name: meal1, dtype: object

```

Работа с файлове в Pandas. CSV.

Един от най-често срещаните начини за съхраняване на големи datasets е чрез използване на csv формата (comma separated values).

```

In [7]: with open('myfile.csv', 'w') as some_csv:
        some_csv.write('first_name, last_name, age, team\n')
        some_csv.write('George, Russell, 25, Mercedes\n')
        some_csv.write('Lando, Norris, 23, McLaren\n')
        some_csv.write('Charles, Leclerc, 25, Ferrari\n')
        some_csv.write('Fernando, Alonso, 41, Aston Martin\n')

```

```

In [8]: import pandas as pd

df = pd.read_csv('myfile.csv')

print(df.to_string())

```

	first_name	last_name	age	team
0	George	Russell	25	Mercedes
1	Lando	Norris	23	McLaren
2	Charles	Leclerc	25	Ferrari
3	Fernando	Alonso	41	Aston Martin

Тук виждаме, че първият ред от .csv файла е header - дава ни информация за данните, които ще намерим в отделните колони. Методът .to_string() извежда целия DataFrame като символен низ.

Някои полезни Pandas методи

- .head(<number_of_rows>) -> Индексира първите N на брой реда от даден DataFrame (по подразбиране първите 5)
- .tail(<number_of_rows>) -> Индексира последните N на брой реда от даден DataFrame (по подразбиране последните 5)
- .info() -> Дава информация за това данново множество - типове данни, брой non-null клетки, заемана памет и т.н.

Самостоятелни задачи:

- Намерете dataset за нещо, което представлява личен интерес в Интернет (kaggle.com е много добра начална точка). Анализирайте намерената от Вас информация и направете заключения за данните.